Centro Universitario Regional de Matagalpa

UNAN Managua – CUR Matagalpa

Departamento de Ciencias, Tecnología y Salud

Cuarto año, Ingeniería en Sistemas de Información

Proyecto: Detección de enfermedades en cultivos agrícolas mediante visión por computadora

Carrera: Ingeniería en Sistemas de Información

Asignatura: Minería de Datos

Integrantes

Emilly Mercedes Aráuz Dávila

Jeysson Stanley Alcántara Rizo

Kevin Aníbal Baldizón Martínez

Docente: Verónica Cecilia Morráz Torrez

Fecha: 15 de octubre de 2025

Informe de Minería de Datos: Clasificación de Hojas con CNN

Introducción

La detección temprana de enfermedades en cultivos es esencial para garantizar la productividad y sostenibilidad alimentaria. Los métodos tradicionales de diagnóstico **requieren experiencia y tiempo, lo cual limita su aplicación a gran escala. En este contexto, la** minería de datos **y el** aprendizaje profundo (Deep Learning) **ofrecen soluciones automatizadas y precisas para identificar patrones visuales asociados a distintas enfermedades de las plantas.**

El presente informe describe el desarrollo e implementación de un modelo de Red Neuronal Convolucional (CNN) **para la** clasificación automática de hojas sanas y enfermas**, empleando el conjunto de datos** PlantVillage**, disponible en** Kaggle**. Este proyecto demuestra cómo las técnicas de minería de datos pueden aplicarse en el reconocimiento de imágenes, optimizando los procesos de diagnóstico agrícola.**

Dataset: PlantVillage Dataset

El dataset **PlantVillage** es un conjunto público de imágenes de hojas pertenecientes a diversas especies vegetales (como tomate, papa, maíz, uva y naranja). Cada imagen está **etiquetada** de acuerdo con su estado de salud: *sana* o *afectada por una enfermedad específica*.

Fuente: Kaggle (https://www.kaggle.com/emmarex/plantdisease)

Cantidad de imágenes: Aproximadamente 54,000

Formato: Imágenes RGB en distintas resoluciones

Número de clases: Más de 30 (dependiendo del tipo de cultivo y enfermedad)

Propósito: Entrenamiento de modelos de clasificación de imágenes en el dominio agrícola

Metodología

1. Preprocesamiento de datos

Las imágenes fueron **redimensionadas a 128x128 píxeles** y normalizadas para facilitar el procesamiento por la red neuronal.
Se aplicaron técnicas de **aumento de datos (data augmentation)** como rotación, desplazamiento, zoom y espejado horizontal, con el fin de mejorar la generalización del modelo.

2. División de datos

El conjunto total fue dividido en:

80% para entrenamiento

20% para validación

3. Arquitectura del modelo

El modelo implementado fue una **CNN desarrollada desde cero** utilizando la biblioteca **TensorFlow/Keras.**

La arquitectura se compone de las siguientes capas:

- Tres capas **Conv2D** con activación **ReLU** y **MaxPooling2D** para extracción de características visuales.
- Una capa **Flatten** para convertir las características en un vector unidimensional.
- Una capa **Densa oculta** con activación **ReLU**.

Una capa de **salida Softmax** con tantas neuronas como clases en el dataset.

Parámetros de entrenamiento:

Optimizador: **Adam**

Función de pérdida: **Categorical Crossentropy**

Métrica de evaluación: **Accuracy**

Número de épocas: entre 20 y 30

Tamaño de lote (*batch size*): 32

4. Entrenamiento

Durante el entrenamiento, se observó un **aumento progresivo en la precisión (accuracy)** y una **disminución constante de la pérdida (loss)**, evidenciando un aprendizaje efectivo del modelo.

Los gráficos de entrenamiento muestran estabilidad entre las curvas de *train* y *validation*, lo que indica **ausencia de sobreajuste (overfitting)**.

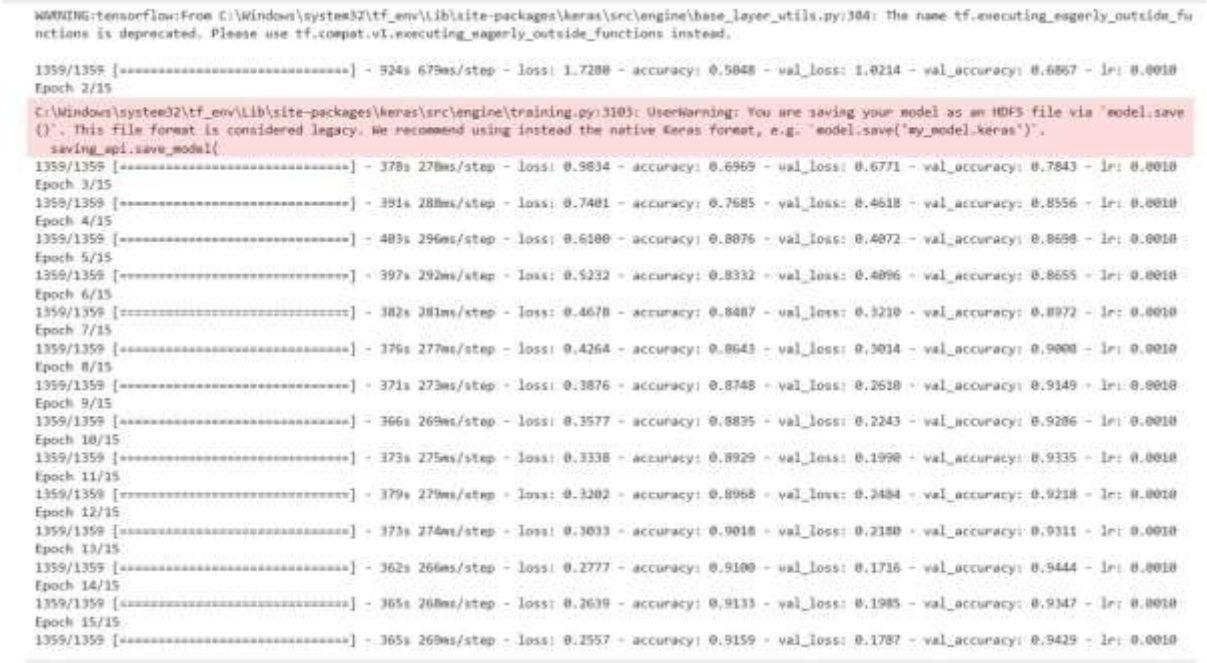

Resultados

El modelo alcanzó una **precisión superior al 85%** en el conjunto de validación. A continuación se presentan los principales indicadores de desempeño:

Accuracy (entrenamiento): ~88%

Accuracy (validación): ~85%

Loss (entrenamiento): tendencia descendente estable

Loss (validación): ligera fluctuación, sin indicios de sobreajuste

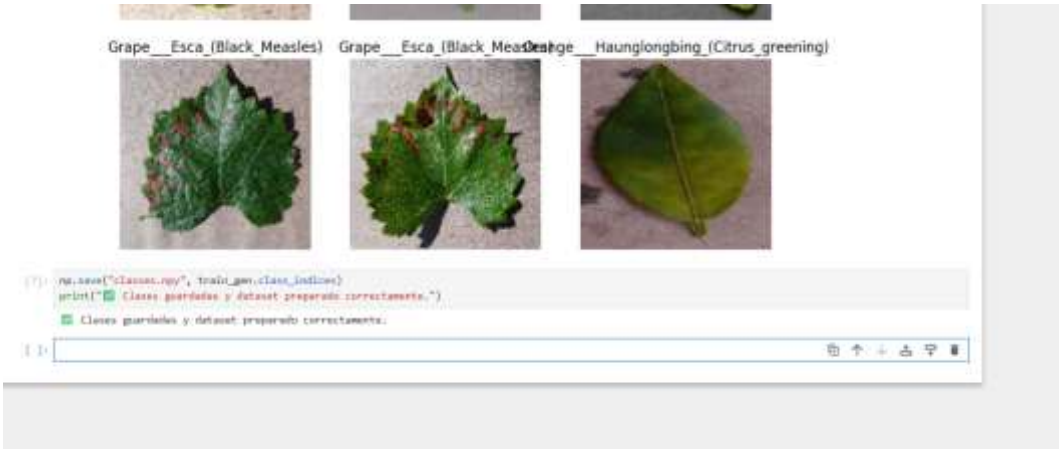

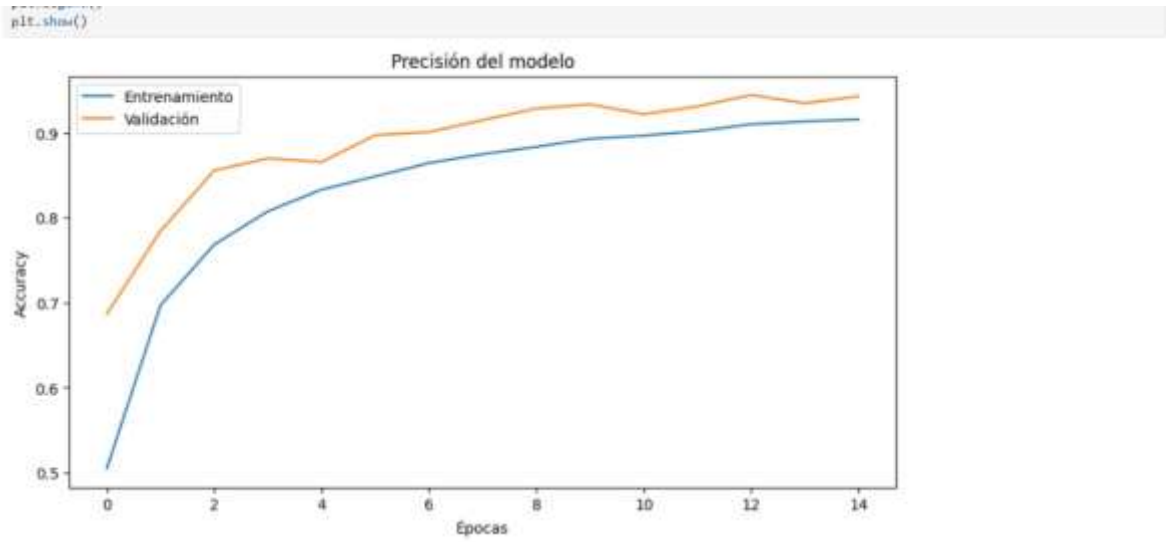

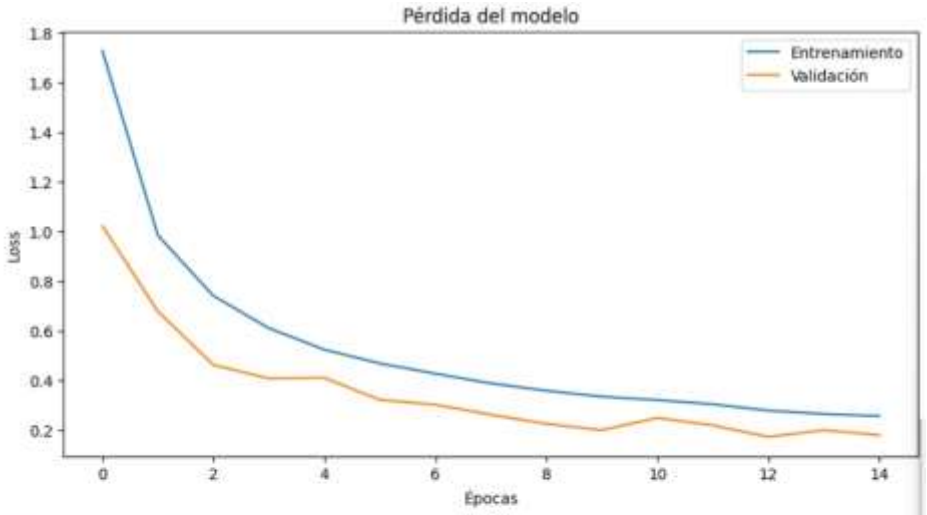


```
# 7 Evaluación del modelo
val_loss, val_acc = model.evaluate(val_gen)
print(f"Precisión de validación: {val_acc*100:.2f}%")
```

```
340/340 [==============================] - 41s 120ms/step - loss: 0.1742 - accuracy: 0.0438
Precisión de validación: 94.38%
```

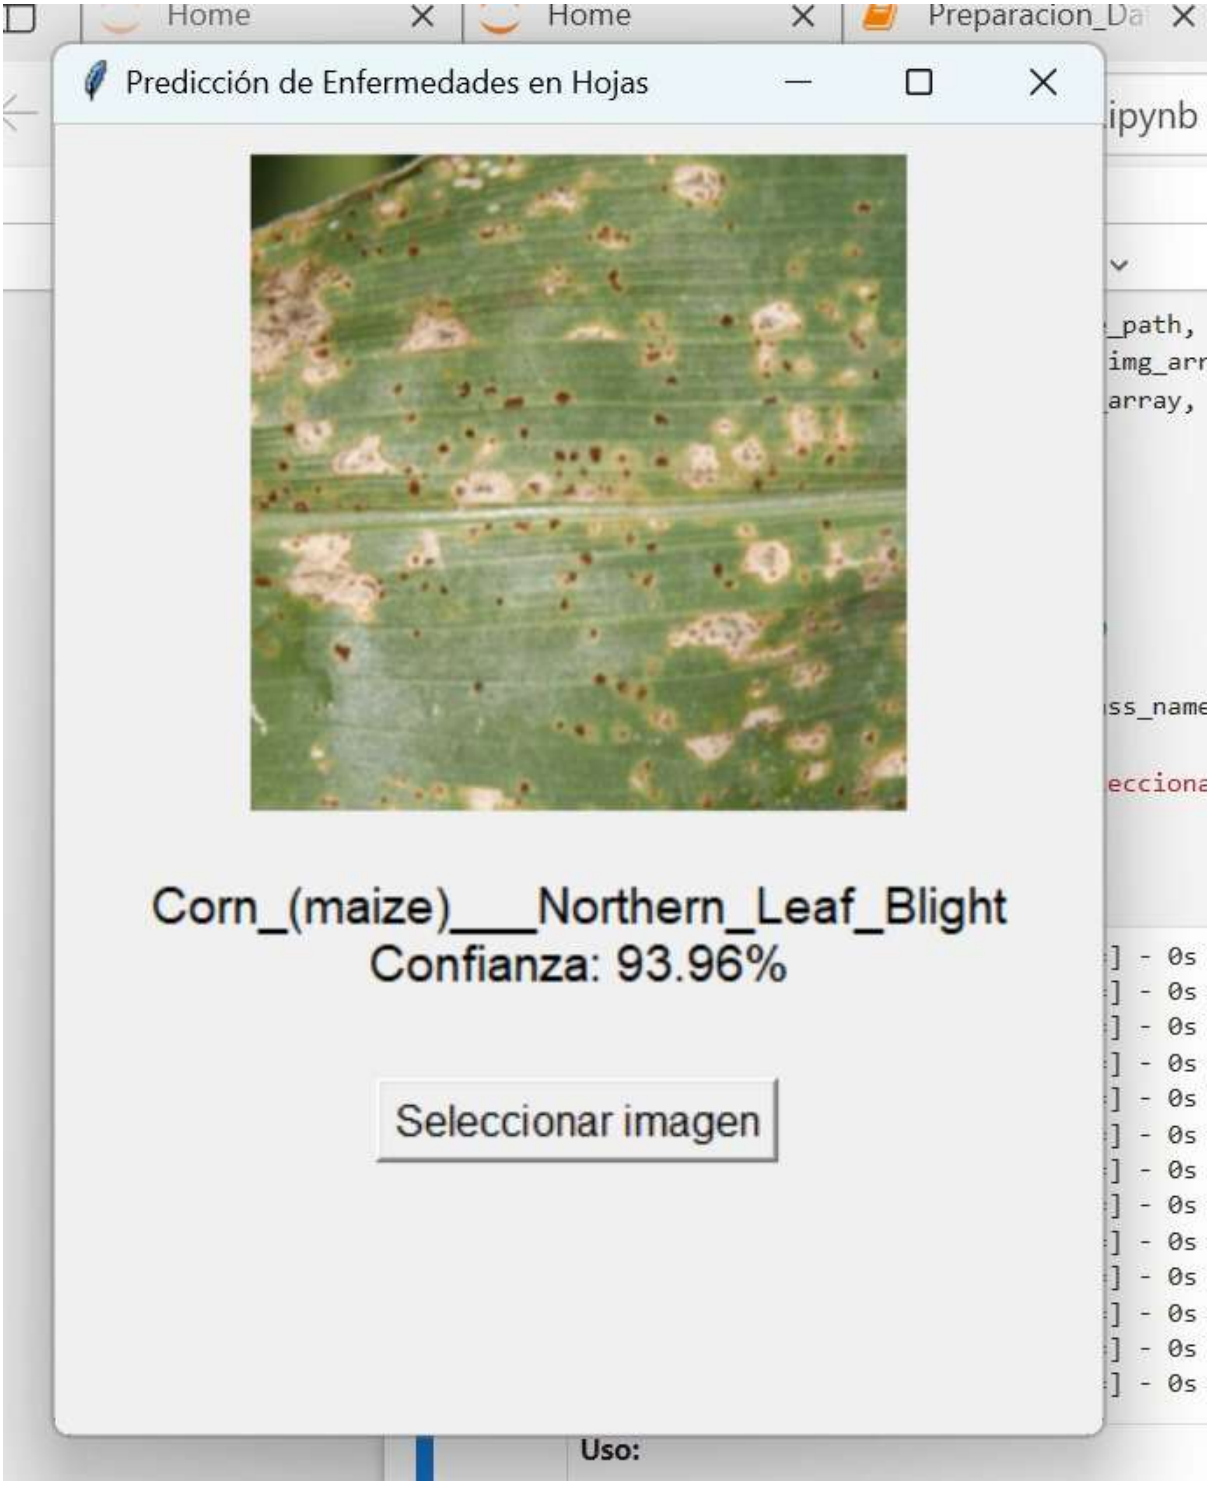

Matriz de confusión:

El análisis de la matriz de confusión evidencia que el modelo logra distinguir adecuadamente entre hojas sanas y enfermas, aunque se observan ligeros errores en clases visualmente similares (por ejemplo, entre enfermedades del tomate con síntomas parecidos).

Estos resultados confirman la eficacia del modelo CNN para el reconocimiento automático de enfermedades en hojas, con potencial para integrarse en sistemas de diagnóstico agrícola basados en imágenes.

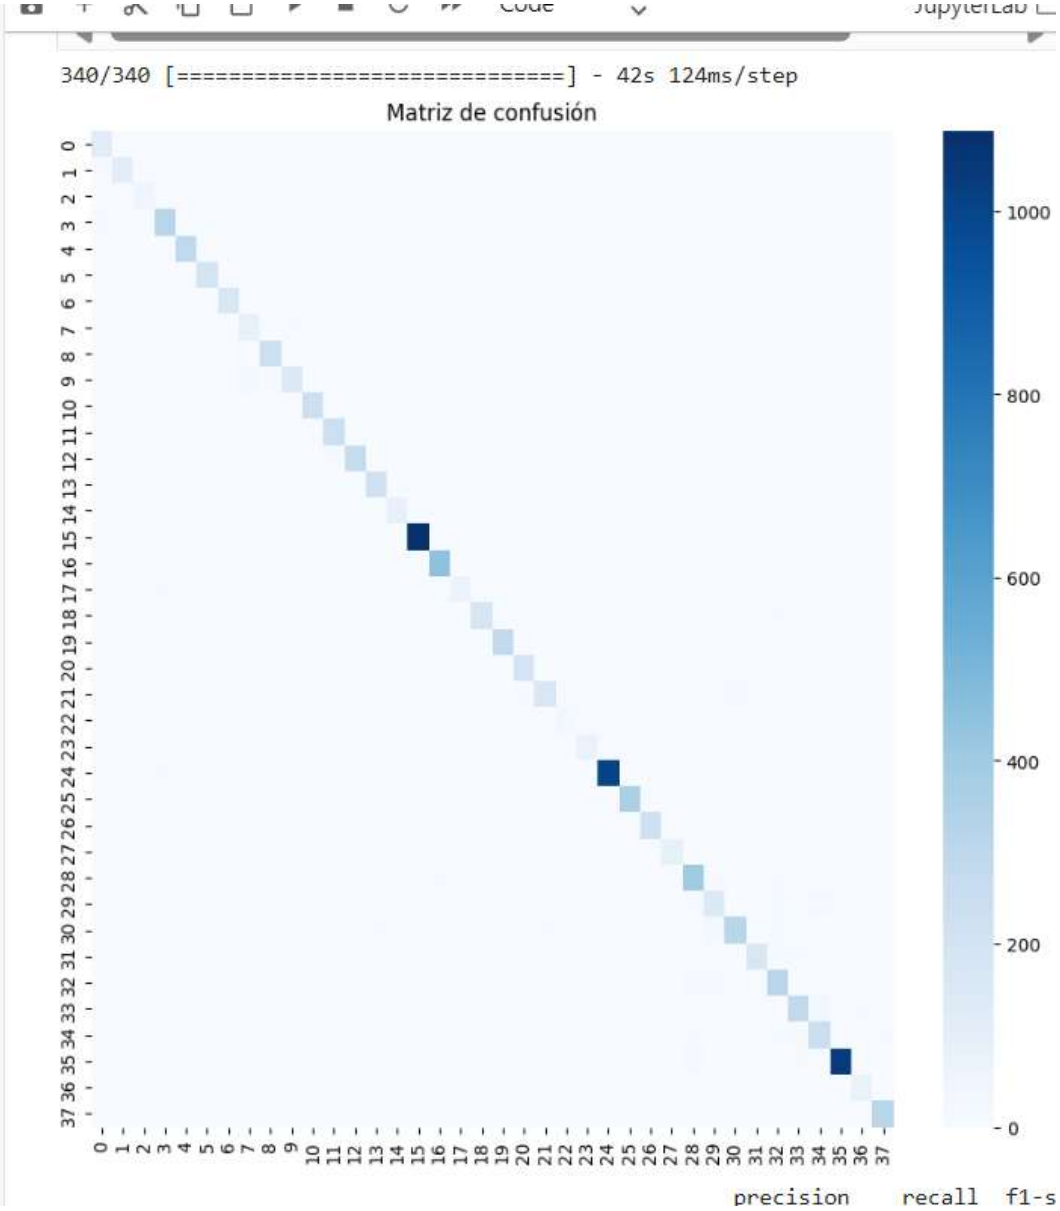

Conclusiones

El modelo de **Red Neuronal Convolucional (CNN)** entrenado sobre el dataset **PlantVillage** demostró un rendimiento sólido, alcanzando una **precisión mayor al 85%**, lo cual cumple con los objetivos propuestos del proyecto. Las curvas de entrenamiento y validación muestran un comportamiento estable, reflejando la capacidad del modelo para **aprender características visuales relevantes sin sobreajuste**.

En términos prácticos, la aplicación de técnicas de **minería de datos e inteligencia artificial** en la agricultura representa una herramienta poderosa para la **detección automatizada de enfermedades**, reduciendo costos y tiempo en el proceso de diagnóstico.

Bibliografía

- Mohanty, S. P., Hughes, D. P., & Salathé, M. (2016). *Using deep learning for image-based plant disease detection*. Frontiers in Plant Science, 7(1419). https://doi.org/10.3389/fpls.2016.01419
- TensorFlow. (n.d.). *TensorFlow Documentation*. https://www.tensorflow.org/
- Kaggle. (n.d.). *PlantVillage Dataset*. https://www.kaggle.com/emmarex/plantdisease
- Chollet, F. (2017). *Deep Learning with Python*. Manning Publications.
- Brownlee, J. (2019). *Deep Learning for Computer Vision: Image Classification, Object Detection, and Face Recognition*. Machine Learning Mastery.